

Augmenter l'historien.ⁱ

Pour une critique computationnelle de l'écriture historique : argumentation, rhétorique réflexivité et modèles de langue

Résumé

Cet article présente un dispositif expérimental d'assistance à l'écriture historique combinant des architectures de type Retrieval-Augmented Generation (RAG) et des modèles de langage (LLM). Contrairement aux usages dominants de ces technologies en sciences humaines — centrés sur l'exploration documentaire ou la génération de texte —, le dispositif proposé vise à formaliser certains aspects récurrents des procédures d'écriture historique en les transformant en signaux analytiques mobilisables par l'historien dans son propre travail critique.

Le pipeline repose sur une articulation en trois niveaux d'analyse complémentaires : le rapport du texte à un corpus bibliographique, appréhendé à travers une taxonomie de relations critiques construite à partir des pratiques historiographiques (confirmation, contradiction, nuance, problématisation, déplacement, particularisation) ; la structure logique de l'argumentation, modélisée à partir des travaux de Toulmin et des schèmes argumentatifs de Walton ; les stratégies rhétoriques, analysées dans le cadre de la Nouvelle Rhétorique de Perelman et Olbrechts-Tyteca, complété par la Rhetorical Structure Theory pour la cohérence discursive locale. Cette combinaison produit une cartographie multi-niveaux des formes argumentatives à l'œuvre dans un texte sous la forme de signaux exploratoires — non des verdicts — qui orientent l'attention de l'historien vers certaines zones de son texte susceptibles de faire l'objet d'une relecture critique.

L'architecture du dispositif repose sur plusieurs principes directeurs : frugalité computationnelle, appropriation par l'utilisateur, lisibilité du code, et attention explicite à la souveraineté des données de recherche. Une distinction est introduite entre un régime batch qui traite l'ensemble d'un manuscrit en produisant des signaux d'orientation, et un régime d'analyse approfondie sur des segments définis par l'historien lui-même. La nature stochastique des LLM, qui conditionne le style même de la programmation, est assumée et documentée plutôt que masquée.

Au-delà de ses applications immédiates, ce travail ouvre la voie à une modélisation computationnelle de l'écriture historique et contribue à définir un programme de recherche à l'interface des humanités numériques, de l'analyse de l'argumentation et de l'épistémologie de l'histoire. Il propose de traiter l'IA non comme un agent de substitution du jugement historien, mais comme une instance à actionner en y encodant des pratiques de métier — un compagnon de la pratique historique plutôt qu'un substitut.

Mots-clés

histoire numérique · humanités numériques · écriture historique · modèles de langage (LLM) · Retrieval-Augmented Generation · analyse argumentative · modèle de Toulmin · nouvelle rhétorique · Rhetorical Structure Theory · réflexivité épistémologique · souveraineté des données · corpus bibliographique · annotation sémantique · littératie numérique · pipeline NLP

Introduction

Le développement récent des modèles de langage et des techniques de recherche sémantique a profondément renouvelé les conditions d'accès aux corpus textuels. Dans le domaine des sciences historiques, ces outils permettent désormais d'interroger des ensembles documentaires volumineux en langage naturel, de produire des synthèses rapidement et d'assister la rédaction comme la traduction de textes. Ces transformations s'inscrivent dans un mouvement plus large de recomposition des pratiques savantes, amorcé avec l'informatisation il y a plusieurs décennies et prolongé aujourd'hui par la généralisation des outils d'intelligence artificielle. Elles soulèvent des questions inédites sur la nature de la preuve historique et sur la continuité — ou la discontinuité — entre les pratiques métiers en univers analogique et leurs reformulations numériques.

Ces transformations s'accompagnent toutefois d'un déplacement plus discret, mais décisif : celui du rapport des chercheurs aux instruments numériques qu'ils mobilisent. Lorsqu'ils sont utilisés comme des services fournis par des plateformes, dont les logiques internes, les choix de formalisation et les effets épistémiques restent largement opaques, ces dispositifs tendent à installer une position essentiellement passive du chercheur, conçu comme utilisateur — ou client. Pour les sciences historiques, ce déplacement soulève un enjeu central : celui du maintien d'une maîtrise réflexive des conditions de production du raisonnement historien.

Cet article s'inscrit explicitement dans ce débat. Il défend la nécessité — et la possibilité — d'une appropriation active et créative des dispositifs numériques en histoire, entendue non comme leur simple usage, mais comme leur mise en forme, leur paramétrage et leur transformation au service des pratiques disciplinaires. Dans cette perspective, les modèles de langage ne sont pas envisagés comme des instruments de délégation du travail intellectuel, mais comme des objets à configurer et à actionner.

C'est dans ce cadre qu'est proposé un dispositif expérimental d'assistance à l'écriture historienne, mobilisable également dans un contexte pédagogique. Celui-ci repose sur des architectures de type Retrieval-Augmented Generation (RAG) et des modèles de langage, non pour produire du texte ou optimiser l'accès à l'information, mais pour analyser le raisonnement en cours d'élaboration. Ce prototype vise à valider la faisabilité d'une proposition méthodologique qui peut également être comprise comme l'esquisse d'un programme de recherche, qui entend s'inscrire dans le prolongement des développements de la recherche au cours des dernières décennies. Les détails techniques, les scripts complets, les tests de variabilité et les exemples de sorties sont disponibles dans le dépôt GitHub associé¹. Le présent papier se concentre sur les principes conceptuels, l'architecture générale et les implications épistémologiques.

Les détails techniques, les scripts complets, les tests de variabilité et les exemples de sorties sont disponibles dans le dépôt GitHub associéⁱⁱ. Le présent papier se concentre sur les principes conceptuels, l'architecture générale et les implications épistémologiques.

¹ Les scripts, la documentation, les exemples de sorties et le corpus de démonstration sont disponibles en libre accès sur GitHub : <https://github.com/Datashs/Git/tree/main/AugmentingHistorians>.

Une première génération d'outils issus de ces développements s'est principalement concentrée sur l'exploration documentaire et la production de contenu. Les architectures de type RAG, qui couplent la recherche vectorielle à la génération par modèle de langage (Lewis et al., 2020), ont notamment rendu possible l'interrogation en langue naturelle de corpus documentaires contrôlés par le chercheur. Ces usages sont désormais bien documentés, même si leurs effets sur les pratiques historiennes restent encore peu étudiés de manière systématique.

Ces approches laissent cependant largement de côté une dimension centrale de la pratique historique : la construction, la validation et la mise à l'épreuve du raisonnement, ainsi que la confrontation de celui-ci à l'historiographie existante. L'écriture de l'histoire ne consiste pas à proposer une synthèse narrative ; elle repose sur une série d'opérations critiques articulant le rapport aux sources, à l'historiographie, la structuration logique des arguments et les stratégies discursives par lesquelles ceux-ci sont rendus recevables dans un cadre donné.

Tout historien connaît, à cet égard, ce moment où il mesure l'écart entre ce qu'il sait avoir lu et ce qu'il aurait dû lire : les centaines, parfois les milliers de publications relatives à l'objet qu'il aborde, dans lesquelles quelqu'un a peut-être déjà formulé l'argument qu'il croit élaborer, ou au contraire en a démontré les limites. C'est de ce souci — à la fois documentaire et argumentatif — que le dispositif présenté ici est partiellement né.

L'intégration des modèles de langage dans les pratiques historiennes pose par ailleurs un problème épistémologique spécifique. Si ces outils facilitent l'accès aux sources et la production de texte, ils tendent également à dissimuler les opérations par lesquelles le texte historien advient : sélection des preuves, enchaînement des arguments, construction des généralisations, positionnement dans les débats historiographiques. Le risque n'est pas seulement celui d'erreurs factuelles — les hallucinations des LLM sont désormais bien documentées (Maynez et al., 2020) — mais celui d'une perte de contrôle sur les modes de validation des arguments historiques, autrement dit d'un affaiblissement de la réflexivité qui fonde la scientificité du travail historique.

Le présent travail propose de déplacer le centre de gravité de ces usages. Plutôt que de traiter les modèles de langage comme des outils de production ou d'exploration documentaire, il les mobilise comme des instruments d'analyse et de mise à l'épreuve du raisonnement — une instance à actionner en y encodant des pratiques de métier. Le dispositif combine ainsi une logique d'exploration documentaire assistée et une logique d'analyse critique, assimilable au travail de relecture que pratique tout historien.

Le pipeline proposé repose sur une articulation en trois niveaux d'analyse complémentaires : le rapport du texte à un corpus bibliographique, appréhendé à travers une taxonomie de relations critiques ; la structure logique de l'argumentation, modélisée à partir des travaux de Toulmin et des schèmes argumentatifs de Walton ; et les stratégies rhétoriques, analysées dans le cadre de la Nouvelle Rhétorique et de la *Rhetorical Structure Theory*. Cette combinaison permet de produire une cartographie multi-niveaux des formes argumentatives à l'œuvre dans un texte, sous forme de signaux exploratoires orientant la relecture critique, plutôt que de diagnostics automatisés.

Ce papier présente d'abord un état de l'art et positionne le dispositif dans la littérature existante, avant de décrire l'architecture du pipeline et ses principes de conception, puis d'exposer les

trois niveaux d'analyse proposés et leur articulation. Il se conclut par une discussion des prolongements possibles de ce travail, envisagé comme une contribution à une histoire numérique fondée sur l'appropriation critique et réflexive des dispositifs computationnels.

État de l'art

Des travaux récents ont permis l'émergence de méthodes destinées à l'analyse, l'exploration et la structuration de corpus textuels de grande taille. Les premières approches, fondées sur la statistique lexicale et la lemmatisation, ont permis d'identifier des régularités de vocabulaire, des cooccurrences et des évolutions diachroniques que la lecture ordinaire ne peut pas appréhender sur de grands volumes (Sinclair & Rockwell, 2016 ; McCarty, 2005). Les procédures développées alors, souvent encodées en des outils logiciels autonomes (Lexico3 (Lamalle Martinez 2001), Txm (Heiden, Magué, Pincemin, 2010)) s'inscrivent dans les traditions de la linguistique de corpus et de la textométrie francophone, qui ont très tôt articulé lexicométrie et interprétation herméneutique. Regroupées sous les étiquettes successives de *text mining*, de *corpus linguistics* appliquée aux sciences humaines, puis de *distant reading* (Moretti, 2013), elles ont en commun de traiter le texte comme un objet dont les propriétés statistiques émergent à l'échelle du corpus plutôt qu'à celle du document ou de l'extrait. L'intérêt de ces approches n'a jamais fait l'unanimité, voire a suscité de vives critiques, dont les plus riches ont été portées par des auteurs insistant sur l'utilité de maintenir un va-et-vient entre *distant* et *close reading* et d'assumer un agnosticisme méthodologique autorisant l'articulation d'outillages provenant de mondes distincts (Underwood, 2019).

Les historiens se sont emparés de ces méthodes de façon inégale. Les travaux pionniers en histoire quantitative avaient déjà montré, dès les années 1960-1970, que le traitement sériel de sources documentaires pouvait révéler des structures invisibles à la lecture cursive (Fogel & Engerman, 1974 ; Furet, 1982). Ce moment fondateur fournit une généalogie méthodologique directe aux approches computationnelles actuelles, en déplaçant l'attention de l'étude de cas singuliers vers des configurations statistiques observables et en favorisant les jeux d'échelle. La numérisation massive des sources primaires et secondaires, qui s'est accélérée dans les années 2000-2010, a ouvert de nouvelles perspectives en rendant accessibles des corpus d'une ampleur inédite — presse numérisée, archives administratives, correspondances — sur lesquels des approches computationnelles pouvaient être appliquées, modifiant aussi bien les conditions de la circulation au sein de vastes corpus documentaires (Burrow 2010) que les conditions de leur analyse (Putnam, 2016). Ces corpus restent toutefois profondément conditionnés par les chaînes de production documentaires et techniques qui ont présidé à leur numérisation, ce qui implique de traiter la disponibilité numérique comme un fait social et technique qui doit être pris en compte par l'analyse (Drucker, 2021).

Le tournant des années 2010 a vu l'émergence de méthodes fondées sur les représentations vectorielles denses du langage, d'abord avec Word2Vec (Mikolov et al., 2013) puis avec les *architectures transformers* (Vaswani et al., 2017). L'architecture transformer a rendu possible l'entraînement de modèles à très grande échelle capables de capturer des dépendances longues dans les textes, préparant directement le terrain pour les grands modèles de langue contemporains. Ces représentations permettent de capturer des relations sémantiques que les approches statistiques classiques ne pouvaient pas appréhender — synonymie, analogie, proximité thématique. Elles ont profondément renouvelé les possibilités d'interrogation de très grands corpus, autorisant à cartographier l'évolution sémantique de concepts historiques sur le temps long (Hamilton et al., 2016) et d'identifier des structures lexicales récurrentes à l'échelle

de corpus massifs afin d'étudier les variations de leur distribution selon les périodes (Underwood, 2019).

L'introduction des grands modèles de langue, à partir de GPT-3 (Brown et al., 2020) puis de ses successeurs, a marqué une autre rupture. Ces modèles manifestent des capacités de compréhension et de génération du langage naturel qui permettent désormais d'interroger des corpus en langue naturelle, de résumer des documents, de classer des textes selon des catégories définies par l'utilisateur, et de produire des analyses sans supervision. Ces tâches correspondent à des opérations intellectuelles traditionnellement constitutives du travail historien, prise de notes, repérage de motifs, qui sont partiellement déléguée à une instance computationnelle. Combinés avec des architectures de récupération vectorielle (*Retrieval-Augmented Generation*, - RAG - Lewis et al., 2020), ils permettent de connecter la puissance générative des LLM à des corpus documentaires spécifiques que le modèle n'a pas vus lors de son entraînement, ouvrant ainsi la voie à des systèmes capables de répondre à des questions en langue naturelle en s'appuyant sur une bibliothèque de sources contrôlée par le chercheur. Ce couplage LLM-RAG est aujourd'hui l'un des principaux paradigmes de l'IA centrée documents. La génération n'y est plus conçue comme autonome, mais comme une interface de reformulation et de mise en relation de sources contrôlées.

Ces développements s'accompagnent d'une réflexion critique sur les limites épistémiques de ces usages : capacité des LLM à produire des affirmations factuellement incorrectes présentées avec assurance (Maynez et al., 2020), dépendance aux biais encodés dans les données d'entraînement (Bender et al., 2021, 613), et difficulté à distinguer ce que le modèle a appris de ce qu'il reconstruit (Bommasani et al., 2021). Ces limites ne sont pas seulement des défauts techniques appelant des solutions d'ingénierie elles dérivent de la nature probabiliste de ces modèles et, dans le cas de leur usage en contexte historien, sur la manière dont ils reconstruisent le passé à partir de distributions textuelles contemporaines.

Les interrogations concernant l'usage de ces outils, dans le contexte historien, laisse quelques angles morts. Ils sont généralement considérés en tant que moyen d'interroger des corpus externes, non comme des outils mobilisés par l'historien dans sa propre écriture, par exemple dans l'analyse et la révision d'un texte en cours d'écriture. En somme l'historien, opérateur passif d'un terminal s'y efface au profit de la complétion des corpus, du grain des données et de l'efficacité des algorithmes. Il est possible cependant de faire réapparaître les gestes, les stratégies, les dialogues qui configurent l'activité historique et conditionnent résultats et conclusions.

Les travaux en *argument mining* computationnel ont montré que l'extraction automatique de structures argumentatives depuis des textes académiques était possible, notamment en mobilisant le cadre de Toulmin (Lawrence & Reed, 2020 ; Stab & Gurevych, 2017), mais ces travaux ciblent principalement des textes délibératifs ou scientifiques, dont la structure argumentative est assez explicite, pas sur des textes dont la structure argumentative est souvent implicite, polyphonique et construite sur le temps long d'un chapitre ou d'un livre. Cela rend rare l'usage de leur modélisation dans le cas de textes historiens marqués par la polyphonie des voix citées et le tissage sur la longue durée. La Nouvelle Rhétorique de Perelman et Olbrechts-Tyteca (1958) est quasi absente du champ de *l'argument mining* computationnel, malgré sa pertinence particulière pour les textes académiques en sciences humaines. Cette absence a été relevée dans des synthèses récentes sur *l'argument mining* (Lippi & Torroni, 2016), sans avoir encore donné lieu à un véritable programme d'intégration. C'est dans cet espace — entre les outils d'interrogation de corpus existants, les outils d'analyse argumentative computationnelle et la tradition d'une histoire instrumentée, que le présent dispositif entend s'inscrire.

Architectures

Le dispositif proposé s'inscrit dans la continuité des pipelines de type *Retrieval-Augmented Generation* (RAG), mais en déplace les finalités. Ces architectures sont généralement conçues pour optimiser l'accès à une documentation abondante afin de produire des réponses pertinentes, le pipeline présenté vise à prolonger ces opérations par une série d'analyses orientées vers la qualification du raisonnement et des argumentaires déployés, en posant que les opérations de recherche documentaire et de génération sont elles-mêmes déjà des actes de construction d'arguments.

L'ensemble des éléments du pipeline a été codé en Python, sous la forme de scripts modulaires, selon une architecture respectant plusieurs principes directeurs dont la conciliation constitue un défi classique d'optimisation sous contrainte (Wieringa, 2014).

La frugalité computationnelle est un premier impératif. Il suppose à la fois une minimisation des appels à des services externes et une économie de puissance de calcul chaque fois que cela est possible. Cela s'inscrit dans le cadre de la sobriété numérique, dont Bordage (2019) a montré qu'elle implique non seulement des choix techniques mais une posture de conception visant à réduire l'empreinte systémique des logiciels. Dans le domaine des SHS computationnelles, aux ressources souvent contraintes, ce principe conditionne la pérennité des outils produits.

Le souci de favoriser l'appropriation par l'utilisateur constitue un deuxième principe structurant. Il se traduit par le regroupement systématique des paramètres et réglages en tête de script. Cela facilite la localisation et la modification des variables de contrôle sans qu'il soit nécessaire de lire l'intégralité du code. Cela implique également la mise possible de paramétrages fins, actionnables parce que le pipeline est accompagné d'explications sur leur signification et leur effet. Cette approche s'inscrit dans les travaux sur l'*end-user programming* et la littératie numérique (Burnett & Myers, 2014) : l'appropriation technique, jamais certaine, suppose non seulement l'accès aux outils mais aussi la capacité à en comprendre les mécanismes de réglage.

Nous souhaitons également favoriser la compréhension des mécanismes mis en œuvre, voire nourrir des apprentissages ce que manifeste une documentation abondante que l'on pourra juger verbeuse. Elle se veut aussi précise et lisible que possible, traduisant en langage naturel les logiques de programmation sous-jacentes à l'usage d'utilisateurs disposant d'une culture informatique modeste, manifestant aussi que le code est un texte qui exprime une posture, une position et parfois une thèse. Cette préoccupation pédagogique s'inscrit dans la longue lignée des travaux sur le *literate programming* initiés par Knuth (1984). Un programme doit être conçu d'abord comme un texte destiné à être lu et compris par des humains, la machine n'en étant qu'un destinataire secondaire. Les formulations plus récentes de ces principes, émergeant souvent des humanités numériques usent d'un autre vocabulaire mais rejoignent ces recommandations en insistant sur la nécessité de rendre les outils computationnels intelligibles aux chercheurs non informaticiens (Ramsay & Rockwell, 2012).

La conciliation de ces différents impératifs est malaisée. Un script abondamment commenté et structuré pour l'appropriation est plus long et potentiellement plus lent qu'un script optimisé pour la seule performance. La modularité facilite la compréhension et la réutilisation, mais peut introduire des surcoûts liés aux appels de fonctions et à la gestion des dépendances. Ces tensions ont été assumées plutôt que résolues, en privilégiant systématiquement la lisibilité et l'appropriabilité plutôt que la performance brute.

Les choix opérés peuvent être lus, prendre sens, et être critiqués, en référence à ce cadre, celui du langage de programmation retenu, Python en fournit un exemple. Ce langage n'est pas le plus économique en temps de calcul — des langages compilés comme C++ ou Rust offrent des

performances nettement supérieures (Pereira et al., 2017). Cependant, il est aujourd'hui le langage le plus largement accessible dans les communautés académiques (Stack Overflow Developer Survey, 2023), et les corpus d'entraînement des grands modèles de langue intègrent de très grands corpus de code python : il est donc particulièrement bien pris en charge par les assistants de type LLM. Cela contribue à créer les conditions de possibilité d'une appropriation par l'utilisateur en lui permettant d'obtenir facilement une redocumentation automatique du code ou des conseils d'adaptation. Dans le cas d'un pipeline de script sans front end, c'est probablement une nécessité. Ce bénéfice n'est pas sans contrepartie : il contribue indirectement à un usage de dispositifs particulièrement consommateurs d'énergie, tension assumée en faisant le pari que la diffusion de la littérature numérique est elle-même une condition de la sobriété. Ajoutons cependant en ce cas, argument peut-être décisif, que Python n'est ici utilisé que comme orchestrateur léger : l'essentiel du temps de calcul (environ 95%) résulte de l'usage de bibliothèques natives ou d'appels LLM, pour la plupart destinés à être effectués localement.

Orchestrer un agent probabiliste

Ce pipeline, qui est un prototype et peut être plus encore un discours historien encodé, ne regroupe pas un ensemble de scripts déterministes. Il constitue un orchestrateur de modèles de langue. Le comportement de ceux-ci est fondamentalement probabiliste. Cette différence de nature a des conséquences sur la façon dont le code est écrit et sur la manière dont ses sorties doivent être interprétées.

Un algorithme classique permet de contrôler un flux d'instructions dont le résultat est prévisible à partir des entrées. Lorsqu'on orchestre un LLM, on négocie avec un agent qui peut interpréter, reformuler ou ignorer partiellement, et ce que recouvre ce partiellement peut considérablement varier, les consignes données, même les plus strictement formulées. C'est ce que Licklider (1960) désignait déjà, dans un autre contexte technique, comme la différence fondamentale entre automatiser une tâche et collaborer avec un système capable d'initiative. Ici la collaboration s'effectue avec un agent dont le comportement est stochastique par nature.

Cette propriété a plusieurs implications. Les expressions régulières utilisées pour extraire les résultats des réponses LLM sont délibérément tolérantes, plutôt que strictes. Il n'y a pas beaucoup d'autres options possibles que chercher un pattern probable plutôt qu'un format garanti, en acceptant des variations de casse, de ponctuation, de positions ou de formulation que le modèle produit, en dépit de l'obstination et des trésors d'ingéniosité déployés dans la rédaction des prompts. Les fonctions de parsing prévoient systématiquement des mécanismes de repli pour les cas où le LLM aurait produit un JSON malformé, omis une section demandée ou restructure sa réponse de façon inattendue. De fait il fait parfois preuve d'une créativité surprenante quoique rarement bienvenue. Des systèmes de sauvegarde intermédiaire et de reprise sur interruption sont intégrés dans les scripts de traitement batch, qui peuvent analyser plusieurs centaines de paragraphes en une seule exécution. La température des modèles est maintenue basse, entre 0.05 et 0.1 selon les scripts, pour réduire la variabilité des sorties.

Le débogage de ces scripts est d'autre part d'une nature particulière. On ne cherche pas un bug logique, plus exactement pas seulement, mais une dérive de comportement probabiliste. Cela suppose des tests dans des configurations variées. Cette dimension stochastique est une limite assumée du dispositif, documentée explicitement dans le code et dans les sorties, plutôt qu'une imperfection à corriger.

Le choix du modèle de langue : une variable épistémique

Le pipeline repose sur des modèles de langue pour produire les analyses argumentatives et rhétoriques. Le choix de ceux-ci n'est pas neutre. La qualité des analyses produites dépend directement de ces choix. Outre la puissance brute des modèles plusieurs facteurs influent sur la nature et la qualité des réponses.

Le premier est la densité de représentation des cadres théoriques mobilisés dans les données d'entraînement. Ceux mobilisés par le pipeline — Toulmin (1958), Perelman & Olbrechts-Tyteca (1958), Mann & Thompson (1988) — sont des théories présentes dans la littérature académique en philosophie, linguistique et rhétorique, leur ancienneté et leur clacicisme même en est un gage. L'efficacité des prompts mobilisant ces cadres repose sur une condition de possibilité rarement formulée explicitement : celle qu'ils soient déjà représentés, avec une densité suffisante, dans les corpus d'entraînement des modèles utilisés. Cette condition n'est pas triviale, vérifier qu'elle soit remplie est malaisé voire impossible, mais elle l'est vraisemblablement pour les théories mobilisées ici. Toulmin et Perelman sont des références classiques de la philosophie analytique et de la rhétorique, abondamment discutées dans la littérature académique en philosophie, en linguistique, en sciences de la communication et dans les manuels d'enseignement de l'argumentation — autant de corpus surreprésentés dans les données d'entraînement des grands modèles de langue. Un modèle peut ainsi, sans avoir jamais été fine-tuné sur une tâche argumentative spécifique, identifier les composantes d'un schéma de Toulmin ou caractériser une technique d'association perelmanienne, parce que les textes décrivant et appliquant ces cadres constituent une part non négligeable de son corpus d'apprentissage.

Cette hypothèse trouve un appui empirique dans des travaux récents. Chen et al. (2024), évaluant les performances de plusieurs LLM sur quatorze jeux de données *d'argument mining* en régime zéro-shot, montrent que ces modèles obtiennent des résultats comparables, voire supérieurs, aux approches supervisées antérieures sur la majorité des tâches argumentatives. Castagna et al. (2024) montrent eux que structurer les prompts à partir des questions critiques associées au modèle de Toulmin améliore significativement les capacités de raisonnement des LLM. Ces performances en régime zéro-shot ou quasi-zéro-shot suggèrent que la familiarité des modèles avec les cadres théoriques classiques de l'argumentation n'est pas un présupposé non contrôlé, mais une propriété documentable de leur corpus d'apprentissage et la condition de possibilité de certains développements.

Cette dépendance aux données d'entraînement constitue cependant une limite qu'il convient d'assumer explicitement. Comme le soulignent Bender et al. (2021), l'analyse produite par un LLM reflète non seulement le cadre théorique invoqué dans le prompt, mais aussi la façon dont ce cadre est représenté — et éventuellement distordu — dans les textes à partir desquels le modèle a appris. Il en résulte que le dispositif proposé ici ne produit pas une analyse de Toulmin ou de Perelman au sens strict, mais une analyse informée par la représentation que les corpus d'entraînement offrent de ces théories. Cette distinction est constitutive de l'épistémologie du pipeline : elle invite à traiter ses sorties non comme des applications mécaniques d'une grille théorique, mais comme des signaux probabilistes orientant l'attention — ce que le dispositif assume par ailleurs explicitement.

La capacité à suivre des formats de sortie contraints est d'autre part très inégalement distribuée. Le pipeline demande aux modèles de produire des réponses structurées selon des formats stricts — scores numériques, composantes Toulmin labellisées, arbres RST en JSON. Cette capacité,

développée par les techniques d'alignement par renforcement (Ouyang et al., 2022), varie significativement selon les modèles et conditionne directement la fiabilité de l'extraction automatique des résultats, les regex utilisés fussent-ils les plus tolérants jamais imaginés.

Dans la version documentée ici, le pipeline utilise gpt-4.1-mini (OpenAI) pour les analyses en mode API et qwen2.5:14b (Alibaba Cloud, via Ollama) pour les analyses en mode local. Ces choix sont largement arbitraires. Pour les usages en API, de nombreuses alternatives existent, le français académique, pour autant que nous puissions le déterminer avec précision, est bien représenté dans les corpus d'entraînement de la plupart des grands modèles. Le caractère générique du plus ancien LLM grand public justifiait seul ce choix lors de la phase de conception. Pour les usages locaux plusieurs modèles *open weights* offrent des alternatives crédibles, avec une empreinte mémoire comparable. Nous avons simplement choisi le modèle le plus puissant parmi ceux qui pouvaient être déployés sur la machine utilisée pour les tests lorsque ceux-ci furent menés. Cela correspond également à ce qu'il est possible d'utiliser sur un laptop disposant de 16 giga de Ram, configuration qui n'est rare aujourd'hui, comme à la taille minimale permettant au pipeline de produire des résultats pertinents, les modèles plus petits s'étant révélés inadaptés.

L'origine chinoise du modèle mérite une mention dans un contexte de recherche européen. Les modèles chinois sont aussi respectueux de la propriété des données que les autres, c'est à dire assez peu. L'usage en mode local résout cependant les problèmes de souveraineté comme ceux de propriété intellectuelle : aucune donnée ne transite vers des serveurs externes. Indépendamment des considérations de coût cela plaide bien sûr pour l'usage d'une architecture locale qui a de plus l'avantage de solliciter des infrastructures énergétiques qui font une assez large place au renouvelable et au nucléaire tout en évitant le recours à une API externe favorisant les usages intensifs voire compulsifs.

Le paysage des LLM évolue à une vitesse qui rend tout choix de modèle obsolète à court terme. C'est une limite assumée ici et encodée dans les scripts qui permettent de changer assez aisément de modèle. La variabilité inter-modèles, et même intra-modèle selon la température et le contexte, est une source d'incertitude que le pipeline tente de contenir par une température basse et des formats de prompt contraints, mais ne peut pas éliminer. Cette dépendance au modèle est ici accentuée par le fait que le dispositif s'appuie délibérément sur la nature des corpus d'entraînement offerts aux grands modèles. Cette variabilité est analogue, en un sens, à la variabilité inter-annotateurs dans les protocoles d'annotation manuelle en linguistique de corpus (Krippendorff, 2004) : elle doit être documentée et assumée plutôt que masquée. Elle peut également dans une certaine mesure du moins, être mesurée, ce que nous n'avons pas fait à ce stade dans la mesure où ce pipeline ne visait pas à la production de métriques stables ou fiables mais à générer des signaux actionnables par l'utilisateur dans un contexte métier où le jugement expert est par l'architecture même, confié à l'utilisateur.

Souveraineté des données et architecture modulaire

La question de la souveraineté des données de recherche est rarement traitée explicitement dans les travaux sur les usages des LLM en humanités numériques, alors qu'elle conditionne directement l'adoption institutionnelle de ces outils. Dans le cadre d'un pipeline d'analyse de manuscrits, deux types de données circulent de façon distincte : les données du corpus bibliographique, d'une part, et les données du manuscrit en cours d'écriture, d'autre part.

L'architecture RAG repose sur une séparation fonctionnelle entre deux composants indépendants : un modèle d'*embeddings* qui produit des représentations vectorielles des textes et permet la recherche par similarité sémantique, et un modèle de langue qui reçoit les passages sélectionnés et produit l'analyse (Lewis et al., 2020). Le modèle de génération ne voit jamais les vecteurs, il reçoit les passages textuels que la recherche vectorielle a identifiés comme pertinents. Cette séparation est une propriété architecturale qui autorise une modularité complète : le choix du modèle de vectorisation et le choix du modèle de génération sont indépendants l'un de l'autre et peuvent être combinés librement. Des évolutions récentes laissent penser que cette indépendance a ses limites et n'est pas garantie à terme, mais elle demeure à l'heure où j'écris ces lignes et dans le contexte d'un dispositif du type discuté ici.

Cette indépendance a des implications directes pour la souveraineté des données. Les modèles d'*embeddings* multilingues disponibles en local — notamment la famille multilingual-e5 (Wang et al., 2024) et les modèles *SentenceTransformers* (Reimers & Gurevych, 2019) — produisent des représentations vectorielles de qualité comparable aux modèles propriétaires pour ce type de tâche, à coût nul et sans exposition de données. L'index vectoriel FAISS (Johnson et al., 2021) est construit et interrogé localement. Le corpus bibliographique ne transite donc jamais vers des serveurs externes si l'on choisit ces composants locaux.

Le pipeline distingue à cet égard trois étapes aux propriétés de souveraineté très différentes, qui correspondent à trois choix que l'utilisateur est appelé à faire.

La première étape est la construction du corpus vectoriel. Les documents du corpus bibliographique sont découpés en segments, encodés en vecteurs par un modèle d'*embeddings*, et indexés dans une base FAISS. Cette étape est entièrement locale si l'on utilise un modèle d'*embeddings* local : aucune donnée ne transite vers l'extérieur et l'index vectoriel réside sur la machine du chercheur.

La deuxième étape est la confrontation manuscrit-corpus. Pour chaque paragraphe du manuscrit, FAISS sélectionne les passages corpus les plus proches sémantiquement. Le LLM reçoit le paragraphe et les passages sélectionnés et qualifie leurs relations selon la taxonomie encodée dans les scripts. Si l'on utilise un LLM externe à cette étape, la totalité du manuscrit transite vers des serveurs tiers paragraphe par paragraphe au fil des appels successifs, de même qu'une notable partie du corpus documentaire utilisé. Même s'il le fera sous la forme de segments courts, cela revient à nourrir gracieusement un opérateur commercial de matériaux dont certains pourraient être sous droit d'auteur. Les sociétés commerciales proposant l'accès à un LLM offrent certes généralement de très vertueuses clauses relatives à la propriété des données, mais il est assez douteux qu'elles soient respectées. Le recours à un modèle local à cette étape, même si c'est au prix généralement d'une qualité d'analyse inférieure, permet de contrôler l'exposition de son manuscrit. Dans le cas de travaux historiens il est possible de considérer que les enjeux de souveraineté sont modestes et que personne ne perdra une guerre ou un marché du fait de l'échappement prématuré d'un manuscrit, ceux de propriété intellectuelle demeurent, ceux liés à la sécurité personnelle de l'auteur dans un régime de surveillance également.


La troisième étape est l'analyse approfondie sur segment. L'historien délimite lui-même les passages de son texte qu'il soumet à une analyse Toulmin, Perelman ou RST. Si le choix est fait de l'usage d'un modèle externe, seuls ces segments transitent vers le LLM externe. Il s'agit là d'une exposition consentie et contrôlée, par opposition à l'exposition systématique de l'étape précédente.

Cette tripartition est ici plus opératoire que la distinction générique local/cloud, parce qu'elle correspond aux choix que l'utilisateur doit faire à chaque étape du traitement, ce qui permet de mettre en scène son statut d'opérateur situé, expert et informé. Un chercheur travaillant sur des archives sensibles ou des hypothèses dont la primauté est en jeu a des raisons légitimes de maintenir l'intégralité de son pipeline en local. Un chercheur dont le corpus est constitué de sources imprimées publiées et dont le manuscrit ne contient pas de résultats inédits sensibles peut recourir à un LLM externe pour bénéficier des modèles les plus performants sur les segments qu'il juge prioritaires. La modularité de l'architecture rend cette décision explicite et réversible plutôt que de l'imposer par défaut, ce qui est logique dans le cadre d'un dispositif qui peut être utilisé dans plusieurs contextes nationaux et au cours d'une période durant laquelle les normes consignes et recommandations des institutions auxquelles il est rattaché peuvent changer, évoluant fréquemment de manière stochastique. Ce choix s'inscrit d'autre part dans la lignée des réflexions récentes sur la *privacy-preserving AI* dans les contextes institutionnels (Mireshghallah et al., 2020).

Les étapes du pipeline sont décrites en détail dans la section suivante. Notons simplement que l'architecture distingue deux régimes d'usage aux propriétés différentes : un régime batch qui traite l'ensemble d'un manuscrit paragraphe par paragraphe en produisant des signaux d'orientation, et un régime d'analyse approfondie sur des segments définis par l'historien lui-même, qui mobilise des cadres théoriques sur des unités textuelles cohérentes. Cette distinction, qui répond aux limites identifiées dans la littérature sur *l'argument mining* automatique (Peldszus & Stede, 2013), structure l'ensemble du dispositif et conditionne l'interprétation et l'usage des résultats produits.

Ce que fait le pipeline

Le parcours de l'historien



Chaque étape peut fonctionner en local (zéro exposition)
ou via API cloud sur les seuls segments consciemment choisis

Ancrages historiographiques

Le premier niveau d'analyse proposé par le pipeline porte sur le rapport entre le manuscrit et un corpus de textes. Dans le contexte de l'élaboration de ce papier et de ce dispositif le manuscrit était relatif à l'histoire de l'extradition et de ses représentations médiatiques au XIX^e siècle. Deux corpus de textes adjoints contenaient l'un des traités et articles juridiques anciens, ce qui levait les difficultés relatives au droit d'auteur et à la propriété intellectuelle dans la phase d'élaboration en cas d'interaction avec une instance externe, l'autre un ensemble d'articles académiques relatifs à l'objet travaillé.

Dans les usages classiques des architectures RAG, les passages sélectionnés dans le corpus sont principalement évalués en termes de pertinence. Ils sont destinés à fournir un contexte adéquat pour la production d'une réponse. Nous déplaçons ce dispositif, en considérant que la relation entre un énoncé et les matériaux qui lui sont associés ne se réduit pas à une question de pertinence, mais relève d'une gamme plus large de rapports critiques, qui caractérisent la manière dont l'auteur d'un texte s'adosse ou s'oppose, ou non, aux textes produits par ses devanciers ou ses contemporains. Il ne s'agit pas ici d'un dialogue avec un corpus de sources, même si bien sûr cette architecture est transposable à d'autres contextes, même si les traités juridiques anciens peuvent être considérés comme des sources imprimées. L'interaction se fait avec un corpus de textes renfermant des énoncés considérés a priori pertinents et légitimes, parce que correspondant à l'horizon historiographie délimité par l'historien lui-même, sans nécessiter de formalisation d'opération de critique historique.

Ce dispositif offre les fonctions classiques d'un RAG. Il permet d'utiliser le corpus constitué comme une base de connaissance au sein de laquelle on identifie les segments les plus pertinents au regard de la question posée, avec la possibilité d'obtenir une synthèse de ceux-ci en langue naturelle. Les segments mobilisés sont cités dans le corps du texte avec un renvoi à leurs coordonnées bibliographiques, de façon à assurer la tracabilité des énoncés et citations proposées et à permettre une vérification directe. Le dispositif peut être connecté à une collection Zotero, outil très utilisé dans la communauté historienne.

Un exemple simple permettra d'illustrer cela. En réponse à la question « rédiger un paragraphe exposant les raisons de préférer Gallicagram à Google Ngram pour un historien », le pipeline retourne un passage rédigé qui identifie douze segments pertinents dans le corpus (le nombre de segments pertinents retenus étant paramétrable), les synthétise en une argumentation structurée, et accompagne, lorsque c'est possible, chaque énoncé d'un renvoi de la forme *[DeCoursonAzoulay2021.pdf, p. 4]* ou *[CoursonAzoulay2023.pdf, p. 7]*. L'historien obtient une proposition d'écriture ancrée dans les textes qu'il a lui-même rassemblés, avec les coordonnées permettant de remonter à la source pour en vérifier le contexte exact.

Le pipeline permet d'autre part de mettre en relation un segment du manuscrit en cours d'écriture, par défaut un paragraphe, partant du principe que le paragraphe correspond à une unité de sens et le corpus bibliographique, en repérant les segments sémantiquement les plus proches de celui-ci et en proposant de les intégrer à l'argumentaire existant. Lorsqu'un passage du corpus est jugé pertinent, le système identifie la citation la plus utile, c'est-à-dire la plus proche, explicite la fonction argumentative de celle-ci dans le contexte du paragraphe examiné, et propose une formulation d'insertion prête à l'emploi, assortie de la référence à la page et au fichier source. C'est ici qu'intervient le principe architectural central. Le manuscrit n'est pas intégré au corpus : il *interroge* le corpus. Chaque paragraphe du manuscrit est traité comme une requête envoyée à l'index, qui retourne les passages documentaires les plus proches par similarité sémantique. Le texte de l'historien reste ainsi un objet actif, situé en dehors du corpus

établi, ce qui interdit toute contamination entre les ressources validées et le propos en construction.

Le pipeline propose de qualifier ces relations à partir d'une série de catégories opératoires, issues de la pratique : confirmation, contradiction, nuance, problématisation, déplacement et particularisation. Ces catégories permettent de décrire, de manière simplifiée mais explicite, les différents modes selon lesquels un passage du corpus peut entrer en relation avec un énoncé du manuscrit, en rapprochant les gestes familiers à l'historien d'une ontologie manipulable. Leur construction suit une logique délibérément inductive : elles ont été stabilisées à partir de situations récurrentes de confrontation entre un énoncé et ses matériaux, en cherchant un niveau d'abstraction suffisant pour être formalisable computationnellement, sans sacrifier la reconnaissance immédiate par le praticien. Le geste correspond à ce que McCarty (2005) désigne comme la condition d'une modélisation réellement heuristique en humanités.

La confirmation désigne les cas où les segments mobilisés apportent un soutien à l'énoncé considéré et convergent avec celui-ci. La contradiction correspond aux situations dans lesquelles les matériaux disponibles s'opposent explicitement à l'énoncé, que ce soit sur le plan factuel ou interprétatif. La nuance renvoie à des cas intermédiaires, où les sources ne remettent pas en cause l'énoncé, mais en limitent la portée. La problématisation désigne les situations dans lesquelles le corpus révèle que l'énoncé correspond à une question débattue dans l'historiographie. Le déplacement correspond aux cas où les matériaux mobilisés suggèrent un autre cadre d'analyse, sans nécessairement invalider l'énoncé initial, mais en le re-situant dans une géographie interprétative différente — autres échelles, autres catégories, autres temporalités. Enfin, la particularisation renvoie aux situations où des exemples ou des cas spécifiques viennent illustrer l'énoncé tout en montrant les limites de la généralisation.

Ces rapports entre le texte pivot et l'univers de textes qui lui sont associés sont suggérés à l'utilisateur, qui peut également les visualiser. Leur mention constitue un signal que le praticien est libre d'ignorer ou de prendre au sérieux. Pour chaque paragraphe analysé, le rapport produit indique le profil dominant, un score de densité documentaire, correspondant peu ou pro au nombre de passages sémantiquement proches du paragraphe du texte soumis au LLM, les passages mobilisables avec leur qualification et leur score de pertinence, les manques identifiés dans la couverture documentaire, et une synthèse en quelques phrases orientant la révision. Ainsi, appliqué au paragraphe d'ouverture d'un manuscrit sur l'histoire de l'extradition au XIX^e siècle, le système retourne un score de densité documentaire élevé, deux passages qui *confortent* le propos offrant une définition juridique précise et sourcée et une réflexion sur la nature paradoxale de la procédure qui articule de manière instable souveraineté et coopération internationale, et un passage qui *nuance* l'affirmation sur l'ancienneté de la pratique en signalant que le terme même d'extradition n'est attesté dans un document officiel français qu'à partir du décret du 19 février 1791. L'information invite à une formulation plus prudente quant à la continuité historique de l'institution et renvoie à la nature particulière d'une pratique très ancienne mais qui n'est juridiquement définie que tardivement.

Appliquée à l'échelle du manuscrit, cette grille d'analyse rend possible une lecture différentielle du texte, où les zones de forte confirmation coexistent avec des zones de contradiction, ou de sous-détermination du texte nouveau par l'existant, et où l'on peut suivre, section par section, les variations du rapport aux textes parents. Ce type de cartographie ouvre la voie à ce que l'on peut qualifier, par analogie, de *critique computationnelle* fournissant un cadre dans lequel les relations entre un texte et ses interlocuteurs sont explicitement qualifiées, comparables et discutables.

Lire un argumentaire historien

Le second niveau d'analyse est de nature différente. Il s'agit moins de demander « est-ce que quelqu'un a dit quelque chose qu'il faudrait prendre en compte ? » que « comment, à partir de quoi, et selon quelles règles de passage, ton texte en vient-il à dire ce qu'il dit ? Là où la cartographie critique opère à l'échelle du paragraphe, l'analyse de segment soumet des unités textuelles plus longues et cohérentes - une séquence argumentative, délimitée par l'historien lui-même - à des modes d'analyse plus ancrés dans une théorisation savante. Trois cadres sont mobilisés. Le premier, issu de la philosophie analytique de l'argumentation, décompose le raisonnement selon le modèle de Toulmin (1958) : thèse, données, loi de passage, appui, nuances et réfutations anticipées sont identifiés et évalués séparément, permettant de repérer les composantes absentes. Cette analyse est redoublée par une modélisation s'appuyant sur Walton (1996), qui permet de qualifier les types de raisonnement à l'œuvre — causalité, argument d'autorité, analogie, argument par conséquence — et d'en évaluer la robustesse. Elle permet notamment de repérer des formes de fragilité argumentative : généralisations hâtives, dépendance excessive à un type de source, recours implicite à des schèmes contestables comme des analogies trop lâches ou des arguments d'autorité mal fondés, ou encore absence de prise en compte de contre-arguments.

Le second cadre est celui de la nouvelle rhétorique élaborée par Perelman et Olbrechts-Tyteca (Perelman & Olbrechts-Tyteca, 1958), qui permet de caractériser les techniques de persuasion à l'œuvre dans le texte, les valeurs mobilisées, le type d'auditoire implicitement visé, et les risques de glissement sophistique. L'écriture de l'histoire en effet ne consiste pas uniquement à articuler des données, des références et des interprétations selon des règles logiques ; elle implique également un travail de mise en forme discursive, orienté vers un auditoire qu'il s'agit de convaincre, au moins provisoirement, d'accepter une certaine manière de voir le passé. Les choix d'exposition, les références mobilisées, les analogies proposées ou les distinctions introduites participent de cette dimension, qui relève de ce que les théories de la rhétorique ont décrit comme les conditions de l'adhésion.

La RST (Rhetorical Structure Theory) intervient ici en complément (Mann & Thompson, 1988) explorant les relations entre entités discursives. Là où la Nouvelle Rhétorique caractérise les stratégies persuasives d'ensemble et la construction de l'auditoire, la RST analyse comment les phrases et les paragraphes s'articulent pour produire de la cohérence ou révèlent, par leurs unités orphelines et leurs ruptures de continuité, les jointures rhétoriques manquantes. Un texte peut ainsi présenter une stratégie persuasive cohérente du point de vue perelmanien tout en articulant faiblement ses unités argumentatives, ou inversement. Cette complémentarité d'échelle est l'une des raisons pour lesquelles les deux cadres sont mobilisés ensemble plutôt que séparément.

Ces analyses distinguent validité logique et efficacité persuasive. Un raisonnement peut apparaître solidement construit du point de vue formel tout en reposant sur des procédés rhétoriques visant à renforcer son acceptabilité ; inversement, un argument plus fragile peut être rendu convaincant par la force de sa mise en forme discursive, une introduction très travaillée, une anecdote initiale particulièrement évocatrice, un usage appuyé de l'analogie, une métaphore ancrée dans une tradition culturelle. Le dispositif ne vise pas à disqualifier ces opérations, qui sont constitutives de toute écriture historienne, mais à les rendre visibles et analysables, en les replaçant dans un ensemble de choix possibles. Elle permet par exemple, de mettre en évidence des formes de prudence discursive, où les modalités, les précautions et les limitations explicites témoignent d'un souci de contrôle des généralisations, que l'on tend parfois à invisibiliser lorsqu'on ne commente le texte qu'en termes de thèse et d'argumentaire associé à celle-ci.

Dans la pratique ordinaire de l'écriture historique, ces relations et ces opérations sont rarement entièrement explicitées. Les enchaînements entre matériaux empiriques et interprétations reposent souvent sur des règles de passage implicites, incorporées par la formation disciplinaire et partagées au sein d'une communauté savante, ce que Bourdieu (1980) désigne comme l'*habitus* disciplinaire, ou Polanyi comme des savoirs tacites (Polanyi 1966) : des dispositions à agir et à raisonner objectivement réglées sans être le produit de l'obéissance consciente à des règles explicites, parfois au point de devenir difficiles à formuler pour les praticiens eux-mêmes. Le dispositif proposé vise précisément à rendre ces opérations visibles.

L'usage pensé du pipeline est de cartographier l'ensemble du texte de façon à repérer les zones qu'il peut être intéressant d'examiner, puis si besoin de fournir un segment argumentatif complet (les modèles utilisés sont modérément pertinents à l'échelle du paragraphe) correspondant aux zones déclarées dignes d'attention par la cartographie d'ensemble parce qu'incluant des paragraphes repérés comme méritant examen.

Le pipeline se comprend ainsi comme un instrument à signaux faibles : conçu non pour diagnostiquer, mais pour orienter l'attention.

Voir le travail de l'historien à l'écritoire

Ces trois cadres peuvent être mobilisés séparément ou combinés dans une synthèse croisée. C'est cette synthèse qui livre les diagnostics les plus opératoires. Soumis à l'analyse Toulmin, un segment du même manuscrit sur l'extradition, portant sur la manière dont l'affaire Lamirande a été couverte par la presse française en 1866, révèle une structure argumentative globalement solide : thèse, données, loi de passage et appui sont tous présents et identifiés. Les données mobilisées sont précises : 259 articles de presse en quelques mois, une correspondance serrée avec les autorités françaises, une documentation abondante. En revanche, la loi de passage entre ces données et la thèse du passage portant sur la mutation narrative de ces récits dans les pages de la presse, reste partiellement implicite. L'analyse rhétorique selon Perelman identifie pour sa part un mouvement allant du constat factuel vers une dissociation critique valorisante, avec un auditoire visé clairement disciplinaire, l'auteur mobilisant les valeurs de rigueur scientifique et d'historicité, sans usage sophistique détecté. L'analyse des structures rhétoriques signale de son côté que les relations entre phrases sont majoritairement des relations d'élaboration à confiance haute, à l'exception d'une relation de contraste entre deux phrases sur la nature du récit médiatique, dont la confiance est qualifiée de moyenne signalant un passage où l'argumentation mériterait d'être rendue plus explicite. La synthèse croisée des trois cadres converge vers un même diagnostic : la solidité de ce segment tient davantage à son ancrage référentiel et à sa précision historique qu'à la robustesse formelle de son argumentation, ce qui se traduit par une recommandation ciblée : expliciter la relation entre les preuves accumulées et la conclusion analytique, et clarifier le warrant sous-jacent pour solidifier la cohérence logique.

De fait l'analyse pointe un passage qui manifeste une tendance repérable dans le texte à ne pas expliciter les opérations menant du matériau à la conclusion dans le contexte d'écriture d'un texte relativement court, témoignant d'une pratique qui n'est qu'à demi consciente consistant à ne pas expliciter les étapes d'un raisonnement lorsque l'on ne dispose que d'un nombre limité de signes, parce que cela prend beaucoup de place et qu'il est douteux que l'éditeur soit prêt à négocier une rallonge.

La combinaison de ces approches permet donc de produire une analyse fine des textes. On peut l'imaginer comme le recours simultané à plusieurs relecteurs, choisis précisément parce qu'ils

sont susceptibles de développer des lectures tout à fait distinctes : l'un attentif à l'ancrage dans la littérature, l'autre à la solidité de l'enchaînement argumentatif, le troisième à la mise en forme rhétorique et à la cohérence discursive, qui n'offrent pas un verdict, moins encore une mesure, mais des conseils, qu'il est possible, comme tous les conseils, d'ignorer.

Perspectives de développement : vers une analyse située des pratiques historiographiques

Le pipeline présenté constitue une première formalisation, encore partielle et délibérément conçue comme un prototype métier d'aide à la rédaction plutôt que comme une plateforme. À ce titre, il doit être compris comme un dispositif évolutif, inscrit dans une démarche exploratoire, dont les développements possibles sont nombreux. Il ne s'agit pas d'un modèle achevé, mais d'un cadre de travail appelé à être discuté, ajusté et, le cas échéant, contredit par ses usages.

Graphes argumentatifs et visualisation

Un premier prolongement concerne la structuration des relations identifiées sous forme de graphes argumentatifs. En représentant les énoncés comme des nœuds et les relations de confirmation, de contradiction ou de nuance comme des arêtes, il devient possible de produire des visualisations du raisonnement à différentes échelles — paragraphe, chapitre, voire ensemble d'un ouvrage. Ces représentations permettraient d'identifier plus aisément les zones de densité argumentative, les points de tension ou les dépendances critiques entre propositions, en offrant à l'historien une vue d'ensemble de structures qu'il ne perçoit souvent que de manière fragmentaire dans la lecture linéaire. Cette direction rejoint les travaux sur la visualisation de l'argumentation développés dans le champ de *l'argument mining* computationnel (Lawrence & Reed, 2020), dont les approches graphiques pourraient être adaptées au contexte de l'histoire.

Vers des outils d'annotation assistée

Un second axe de développement, qui est un possible non une promesse à ce stade, concerne la possibilité d'un usage en annotation semi-assistée. Les analyses produites par le pipeline, classifications relationnelles, composantes Toulmin, techniques Perelman, relations RST, constituent des pré-annotations que des historiens formés pourraient réviser, valider ou corriger, selon le modèle de l'annotation humain-machine en boucle désormais bien établi dans le champ de *l'argument mining* (Lindahl, 2024). De tels corpus annotés, constitués à partir des analyses du pipeline et corrigés par des experts, constitueraient des ressources précieuses pour l'étude empirique de l'argumentation en sciences historiques — et pourraient, à terme, alimenter des approches d'apprentissage supervisé capables de proposer des diagnostics plus fins.

Cette perspective soulève cependant des questions importantes. La conversion de signaux orientés vers l'historien au travail en données d'entraînement pour des modèles automatiques suppose une réflexion sur les conditions de validité et de transférabilité de ces annotations dans des contextes historiographiques variés, ainsi que sur la place laissée au jugement humain dans leur interprétation. Des signaux conçus pour orienter une révision peuvent se trouver traités comme de quasi mesures s'ils alimentent un modèle sans précaution suffisante — risque bien identifié dans la littérature sur l'annotation computationnelle de l'argumentation (Lawrence & Reed, 2020 ; Lindahl, 2024).

Analyse comparative des styles argumentatifs

Un troisième prolongement concerne l'analyse comparative des pratiques argumentatives. En appliquant le dispositif à des corpus différenciés — selon des périodes, des espaces ou des traditions historiographiques — il devient envisageable de comparer les manières de mobiliser les sources, la bibliographie, de structurer les arguments ou de recourir à certaines stratégies rhétoriques. Une telle approche ouvrirait la voie à une analyse empirique des styles de raisonnement en histoire, en écho aux travaux de Crombie (1994) sur les styles de pensée scientifique et à leur reformulation philosophique par Hacking (1992), mais en les ancrant cette fois dans des descriptions systématiques de textes historiens, plutôt que dans des catégories très générales.

À ce stade, le pipeline produit délibérément des signaux qualitatifs suggérant une intervention et une vérification humaines plutôt que des métriques exploitables directement. Une extension quantitative n'est pas exclue, mais elle supposerait de mesurer préalablement la stabilité des valeurs centrales obtenues sur des corpus de textes établis, afin de déterminer si elles permettent effectivement de discriminer des styles argumentatifs, ce qui constitue une direction de recherche possible, nullement implémentée à ce stade.

Ces perspectives peuvent être articulées avec des traditions déjà bien établies. La mise en relation des structures argumentatives avec des analyses lexicométriques permettrait d'explorer les liens entre formes de raisonnement, configurations discursives et thésaurus à plus grande échelle. De même, une articulation avec des approches prosopographiques ouvrirait la possibilité de relier les styles argumentatifs à des trajectoires, des positions institutionnelles ou des appartenances disciplinaires, en inscrivant les textes dans les contextes sociaux de leur production. On pourrait ainsi envisager, à terme, une histoire sociale et intellectuelle des pratiques argumentatives, fondée sur des indices explicitement modélisés plutôt que sur des impressions de lecture, certes parfois informées, mais garanties fragile de généralisation

Usages immédiats : évaluation de manuscrits et pédagogie de l'écriture

Les développements qui précèdent dessinent un possible programme de recherche à moyen et long terme. Il convient cependant de ne pas laisser dans l'ombre les usages les plus immédiats du dispositif, qui ne supposent aucun développement supplémentaire et répondent à des besoins documentés. Ils dérivent de l'ancrage du développement dans une pratique métier sous ses différents aspects puisque l'élaboration de l'outil n'a jamais été dissociée du souci d'instrumenter une pratique.

Le premier est celui de l'évaluation de manuscrits, qu'il s'agisse de mémoires, de thèses ou d'articles soumis à des revues. Les rédacteurs en chef de revues académiques se heurtent à une difficulté croissante : trouver des chercheurs disponibles et compétents pour évaluer les manuscrits qui leur sont soumis. Ce phénomène, désigné dans la littérature sous le terme de *reviewer fatigue*, se traduit par des délais d'évaluation qui excèdent désormais cent jours en moyenne, certaines revues nécessitant plus de six mois pour rendre une décision, avec des conséquences directes sur les trajectoires des jeunes chercheurs. Dans ce contexte, le pipeline ne se substitue pas au jugement disciplinaire d'un relecteur expert — dont la compétence thématique et l'inscription dans des débats vivants restent irremplaçables — mais il peut produire, en amont de ce jugement ou en complément de celui-ci, une cartographie structurée de la solidité argumentative d'un texte, de son positionnement dans l'historiographie et de ses stratégies rhétoriques. Il offre ainsi un premier niveau d'analyse formalisé qui peut orienter la

lecture du relecteur humain, ou permettre à l'auteur de renforcer son manuscrit avant soumission.

Le deuxième usage immédiat est pédagogique. L'enseignement de l'écriture académique en histoire — et plus largement dans les sciences humaines — repose le plus souvent sur des formes de compagnonnage peu formalisées : le directeur de mémoire qui annote, les participants au séminaire qui discutent le premier état d'un texte, le collègue qui relit. Ces pratiques sont précieuses mais inégalement accessibles. Des travaux récents montrent que les retours générés par des LLM sur des écrits argumentatifs étudiants peuvent être efficaces, notamment lorsqu'ils s'inscrivent dans un cadre pédagogique explicite plutôt que dans un usage non guidé — les LLM peuvent jouer plusieurs rôles dans le développement des compétences argumentatives, notamment en fournissant des retours évaluatifs ou en s'engageant comme partenaire de travail collaboratif (Su et al., 2023). Appliqué à des textes produits par des étudiants de master ou de doctorat, le pipeline propose une modalité d'analyse qui va au-delà de la correction stylistique : il rend visible la structure argumentative d'un texte, l'identifie par rapport à un corpus historiographique fourni par l'enseignant, et permet à l'étudiant d'observer, sur son propre texte, les catégories qu'il est par ailleurs invité à maîtriser.

Le troisième usage est la lecture analytique de textes canoniques du domaine. Soumettre un article classique de la discipline — un texte de Furet, de Ginzburg, de Davis — à l'analyse du pipeline n'a pas pour but d'en produire une évaluation, mais d'en éclairer la construction selon quels schèmes argumentatifs organise-t-il sa démonstration ? quelles techniques rhétoriques assurent sa réception dans la communauté disciplinaire ? Ce type d'analyse outillée d'un texte établi constitue un exercice pédagogique en soi, qui donne à voir des opérations d'écriture que la lecture ordinaire laisse le plus souvent dans l'implicite. Il rejoint en ce sens les préconisations d'une tradition réflexive bien établie en didactique de l'écriture académique, qui insiste sur la nécessité de rendre explicites les conventions disciplinaires que les étudiants sont censés incorporer (Lea & Street, 1998).

Localisation et adaptations culturelles

Une dimension rarement discutée dans la littérature sur les outils d'analyse de textes académiques mérite d'être signalée : le dispositif est conçu et calibré pour des textes en français, dans une tradition historiographique européenne. Son extension à d'autres langues et traditions culturelles supposerait un travail d'adaptation substantiel probablement non pas seulement linguistique. Les normes d'écriture historique, les conventions de citation, les modes d'engagement avec l'historiographie, les registres rhétoriques acceptables varient considérablement selon les traditions nationales et disciplinaires. Un dispositif calibré sur la tradition française peut produire des diagnostics biaisés appliqué à des textes relevant de traditions argumentatives différentes — historiographie germanophone, latino-américaine ou asiatique, pour n'en citer que quelques-unes. Cette limite est constitutive du projet à ce stade, et son dépassement supposerait une collaboration interdisciplinaire et interculturelle largement au-delà de ce que le présent travail peut engager.

Interfaces interactives et accessibilité

Le développement d'interfaces interactives constitue un autre enjeu important. L'intégration du pipeline dans des environnements d'écriture ou de lecture pourrait permettre de proposer une assistance critique en temps réel, signalant des tensions avec le corpus, des fragilités argumentatives ou des généralisations insuffisamment étayées. Un tel usage rapprocherait le

dispositif des pratiques ordinaires de relecture, qu'il s'agirait d'outiller sans les transformer en procédures automatisées, en laissant à l'historien la décision de suivre ou non les signaux proposés.

À ce jour, le pipeline suppose de savoir travailler en mode console, de maîtriser suffisamment Python pour installer un environnement adapté et lancer un script, et de disposer d'une machine assez puissante pour faire tourner des modèles LLM locaux dans des conditions acceptables. Nous sommes conscients que ces conditions ne sont pas toujours réunies, et qu'une documentation aussi précise et détaillée que possible — certains diraient bavarde et verbeuse — ne suffit pas à effacer ces barrières à l'entrée. L'extension à d'autres disciplines de production de discours savants, dont les normes argumentatives ne sont pas si éloignées de celles des historiens, supposerait par ailleurs un travail d'adaptation et de formalisation largement au-delà des objectifs et des compétences mobilisées dans le cadre du présent travail.

Limites structurelles

Ces perspectives ne doivent pas faire oublier les limites du dispositif, en son état actuel comme dans ses caractéristiques structurantes. La qualité des analyses dépend étroitement du corpus mobilisé, des choix de segmentation et des paramètres des modèles utilisés. Les catégories proposées restent simplificatrices et ne peuvent rendre compte de toute la complexité des raisonnements historiques. Enfin, le risque d'une réification des résultats, traiter comme des verdicts ce qui n'est conçu que comme des signaux, appelle à maintenir une distance critique constante à l'égard des sorties produites.

L'enjeu n'est donc pas de substituer des procédures computationnelles au jugement historien, mais de développer des instruments permettant d'en expliciter certaines dimensions. Le pipeline peut ainsi être envisagé comme un outil d'exploration réflexive, destiné à accompagner la pratique plutôt qu'à la normer, et à ouvrir un espace de discussion sur ce que les historiens font effectivement quand ils écrivent, lisent et évaluent des textes.

Conclusion

Le dispositif présenté dans cet article ne constitue pas seulement un outil technique destiné à améliorer l'exploration des corpus ou à assister la rédaction. Il propose une première formalisation instrumentée des opérations par lesquelles se construit, se justifie et se discute le raisonnement historien, à l'usage de l'historien au travail, comme de l'historien des pratiques historiennes ou de l'épistémologue, et peut-être d'autres encore, tant on n'est jamais certain des usages des dispositifs que l'on met en circulation. En articulant l'analyse du rapport à la bibliographie, la structure argumentative et les stratégies rhétoriques, il vise à rendre visibles des dimensions du travail historien qui demeurent le plus souvent implicites, et que l'on appréhende d'ordinaire à travers l'expérience, le compagnonnage ou la relecture, plutôt que par des descriptions explicites.

Ce déplacement conduit à considérer les architectures issues des modèles de langage non plus comme de simples dispositifs de production de texte, mais comme des environnements d'analyse et de mise à l'épreuve du raisonnement. La génération n'y apparaît plus comme une fin, mais comme un moment dans un processus plus large d'examen critique, où les énoncés sont situés, comparés et discutés, en relation avec des corpus et des traditions historiographiques identifiables. L'IA n'est pas ici quelque chose à fuir ou à subir, mais une instance à actionner

— à condition de l'actionner en y encodant des pratiques de métier, plutôt que de se laisser imposer les normes implicites, et souvent opaques, qui règlent l'interaction avec les plateformes commerciales.

L'ambition de ce travail reste volontairement limitée. Il ne s'agit ni de proposer une modélisation exhaustive du raisonnement historien, ni de substituer une évaluation computationnelle au jugement disciplinaire ni d'un générateur de manuels. Le pipeline demeure exploratoire, dépendant des corpus mobilisés et des choix de formalisation opérés. Ses résultats doivent être interprétés comme des indicateurs, non comme des verdicts, et comme des invitations à relire, à nuancer ou à déplacer plutôt que comme des prescriptions de réécriture, même si l'on n'est jamais certain que les usagers se conforment toujours à la posologie.

Ce travail ouvre cependant une perspective plus large. En rendant analysables et comparables des opérations longtemps incorporées, il contribue à déplacer le regard du texte vers les pratiques qui le produisent. Il suggère ainsi la possibilité d'une instrumentation de la critique historiographique elle-même, entendue non comme un ensemble de règles explicites, mais comme un ensemble de gestes, de choix et d'arbitrages inscrits dans l'écriture, susceptibles d'être repérés décrits, discutés et, dans une certaine mesure, comparés.

Dans cette perspective, la figure de l'historien augmenté ne renvoie pas à une délégation du travail à des systèmes automatisés, mais à une extension des capacités de réflexivité sur les conditions de production du savoir historique qui code explicitement la place de l'historien comme détenteur instrumenté d'un jugement expert. L'enjeu n'est pas d'automatiser l'histoire, mais de rendre plus visibles, plus discutables et peut-être plus comparables les formes de raisonnement qui la constituent — en faisant de l'instrumentation computationnelle non un substitut, mais un compagnon de la pratique historique, dont l'appropriation est nécessaire (Rygiel 2017), parce que ne pas être en capacité d'intervenir sur le choix des techniques et les techniques revient à déléguer des choix dont nous pensons avoir montré qu'ils sont tout autant épistémiques que politiques.

Il est vain d'espérer limiter ou interdire l'usage des LLM par les professionnels comme par les étudiants, ne serait-ce que parce que vouloir éviter l'usage d'instances permettant de forts gains de productivité dans un environnement social concurrentiel ne peut que produire la marginalisation de ceux qui vertueusement s'abstiennent, à moins qu'ils ne soient à l'abri d'un statut. Il est peut-être possible par-contre de construire, en dialogue avec ceux dont concevoir, coder et modéliser est le métier, des usages qui nourrissent la réflexivité des praticiens plutôt que de se résigner à une délégation à une instance opaque des opérations de génération de leurs textes, c'est à dire de leur pensée. Nous rejoignons ici certaines des perspectives tracées par Jo Guldi, plaidant pour, dans certains contextes, un encodage réflexif du geste historien (Guldi, 2014).

Il reste à préciser dans quel esprit ce compagnonnage est ici proposé. Le code produit dans le cadre de ce travail a quelque chose d'un cahier des charges ou d'une proposition. Il formule explicitement, sous une forme discutable et modifiable, les choix de formalisation opérés sur les pratiques du métier. À ce titre, il appelle moins à une adoption passive qu'à un dialogue : avec les historiens qui voudraient éprouver, amender ou contester ces choix à partir de leurs propres pratiques, avec les développeurs qui pourraient les prolonger dans d'autres directions, avec les épistémologues qui trouveraient dans ces formalisations une matière à discussion. C'est en ce sens que l'appropriation visée n'est ni passive ni cliente : elle suppose une interaction réflexive avec le dispositif, qui inclut la possibilité de le remettre en question jusque dans ses fondements.

Bibliographie

Aaronson, S. (2023). "The case for AI safety via privacy." **Communications of the ACM**, 66(8), p. 38-41.

Bender, E. M., Gebru, T., McMillan-Major, A. & Shmitchell, S. (2021). "On the dangers of stochastic parrots: Can language models be too big?" **Proceedings of the 2021 ACM Conference on Fairness, Accountability, and Transparency (FAccT)**, p. 610-623.

Bommasani, R. et al. (2021). "On the opportunities and risks of foundation models." **arXiv**, 2108.07258.

Bordage, F. (2019). **Sobriété numérique : les clés pour agir**. Paris : Buchet-Chastel.

Bourdieu, P. (1980). **Le sens pratique**. Paris : Les Éditions de Minuit, 480 p.

Brown, T., Mann, B., Ryder, N., Subbiah, M., Kaplan, J., Dhariwal, P., Neelakantan, A., Shyam, P., Sastry, G., Askell, A. et al. (2020). "Language models are few-shot learners." **Advances in Neural Information Processing Systems**, 33, p. 1877-1901.

Burnett, M. & Myers, B. (2014). "Future of end-user software engineering: Beyond the silos." **Proceedings of FOSE 2014, ICSE**, p. 201-211.

Burrow, J. (2010). **A History of Histories**. London : Penguin.

Castagna, F. et al. (2024). "Critical-Questions-of-Thought: Steering LLM reasoning with argumentative querying." *arXiv*, 2412.15177.

Chen, G., Cheng, L., Luu, A. T. & Bing, L. (2024). "Exploring the potential of large language models in computational argumentation." *Proceedings of ACL 2024*, p. 2309-2330.

Crombie, A. C. (1994). **Styles of Scientific Thinking in the European Tradition: The History of Argument and Explanation Especially in the Mathematical and Biomedical Sciences and Arts**. 3 vol. London : Duckworth.

Drucker, J. (2021). **The Digital Humanities Coursebook: An Introduction to Digital Methods for Research and Scholarship**. London : Routledge.

European Parliament & Council of the European Union (2016). **Regulation (EU) 2016/679 of the European Parliament and of the Council of 27 April 2016 on the protection of natural persons with regard to the processing of personal data (General Data Protection Regulation)**. **Official Journal of the European Union**, L 119, p. 1-88.

Fogel, R. W. & Engerman, S. L. (1974). **Time on the Cross: The Economics of American Negro Slavery**. Boston : Little, Brown.

Furet, F. (1982). **L'Atelier de l'histoire**. Paris : Flammarion.

Hacking, I. (1992). "'Style' for historians and philosophers." **Studies in History and Philosophy of Science**, 23(1), p. 1-20.

Hamilton, W. L., Leskovec, J. & Jurafsky, D. (2016). "Diachronic word embeddings reveal statistical laws of semantic change." **Proceedings of the 54th Annual Meeting of the Association for Computational Linguistics**, p. 1489-1501.

Heiden, S., Magué, J.-P. & Pincemin, B. (2010). "TXM : Une plateforme logicielle open-source pour la textométrie — conception et développement." In Bolasco, S., Chiari, I. & Giuliano, L. (dir.), **Statistical Analysis of Textual Data. Proceedings of the 10th International Conference JADT 2010**, Rome : Edizioni Universitarie di Lettere Economia Diritto, vol. 2, p. 1021-1032. HAL : halshs-00549779.

Guldi, J. & Armitage, D. (2014). *The History Manifesto*. Cambridge : Cambridge University Press. Disponible en open access : <http://historymanifesto.cambridge.org>

Johnson, J., Douze, M. & Jégou, H. (2021). "Billion-scale similarity search with GPUs." **IEEE Transactions on Big Data**, 7(3), p. 535-547.

Knuth, D. E. (1984). "Literate programming." **The Computer Journal**, 27(2), p. 97-111.

Krippendorff, K. (2004). **Content Analysis: An Introduction to Its Methodology**. 2e éd. Thousand Oaks : Sage Publications.

Lamalle, C., Martinez, W., Fleury, S., Salem, A., Fracchiolla, B., Kuncova, A. & Maisondieu, A. (2004). **Lexico3 Textometric Toolbox. User's Manual**. Travaux du SYLED-CLA2T, Université Sorbonne Nouvelle — Paris 3, 48 p. HAL : hal-01224049.

Lawrence, J. & Reed, C. (2020). "Argument mining: A survey." **Computational Linguistics**, 45(4), p. 765-818.

Lea, M. R. & Street, B. V. (1998). "Student writing in higher education: an academic literacies approach." *Studies in Higher Education*, 23(2), p. 157-172

Lewis, P., Perez, E., Piktus, A., Petroni, F., Karpukhin, V., Goyal, N., Küttler, H., Lewis, M., Yih, W., Rocktäschel, T., Riedel, S. & Kiela, D. (2020). "Retrieval-augmented generation for knowledge-intensive NLP tasks." **Advances in Neural Information Processing Systems**, 33, p. 9459-9474.

Licklider, J. C. R. (1960). "Man-computer symbiosis." **IRE Transactions on Human Factors in Electronics**, HFE-1(1), p. 4-11.

Lindahl, A. (2024). "Annotation for computational argumentation analysis: Issues and perspectives." **Language and Linguistics Compass**, 18(1), e12505. DOI : 10.1111/lnc3.12505.

Lippi, M. & Torroni, P. (2016). "Argumentation mining: State of the art and emerging trends." **ACM Transactions on Internet Technology**, 16(2), article 10.

Mann, W. C. & Thompson, S. A. (1988). "Rhetorical Structure Theory: Toward a functional theory of text organization." **Text**, 8(3), p. 243-281.

Maynez, J., Narayan, S., Bohnet, B. & McDonald, R. (2020). "On faithfulness and factuality in abstractive summarization." **Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics**, p. 1906-1919.

McCarty, W. (2005). **Humanities Computing**. Basingstoke : Palgrave Macmillan.

Mikolov, T., Sutskever, I., Chen, K., Corrado, G. & Dean, J. (2013). "Distributed representations of words and phrases and their compositionality." **Advances in Neural Information Processing Systems**, 26, p. 3111-3119.

Mireshghallah, F., Tramèr, F., Carlini, N. et al. (2020). "Privacy in deep learning: A survey." **arXiv**, 2004.12254.

Moretti, F. (2013). **Distant Reading**. London : Verso.

Ouyang, L., Wu, J., Jiang, X. et al. (2022). "Training language models to follow instructions with human feedback." **Advances in Neural Information Processing Systems**, 35, p. 27730-27744.

Peldszus, A. & Stede, M. (2013). "From argument diagrams to argumentation mining in texts: A survey." **International Journal of Cognitive Informatics and Natural Intelligence**, 7(1), p. 1-31.

Pereira, R., Couto, M., Ribeiro, F., Rua, R., Cunha, J., Fernandes, J. P. & Saraiva, J. (2017). "Energy efficiency across programming languages." **Proceedings of SLE 2017**, ACM, p. 256-267.

Perelman, Ch. & Olbrechts-Tyteca, L. (1958). **Traité de l'argumentation. La nouvelle rhétorique**. Paris : Presses Universitaires de France, 2 vol.

Putnam, L. (2016). "The transnational and the text-searchable: Digitized sources and the shadows they cast." **The American Historical Review**, 121(2), p. 377-402.

Ramsay, S. & Rockwell, G. (2012). "Developing things: Notes toward an epistemology of building in the digital humanities." In Gold, M. K. (dir.), **Debates in the Digital Humanities**. Minneapolis : University of Minnesota Press.

Reimers, N. & Gurevych, I. (2019). "Sentence-BERT: Sentence embeddings using Siamese BERT-networks." **Proceedings of the 2019 Conference on Empirical Methods in Natural Language Processing (EMNLP)**, p. 3982-3992.

Rygiel, P. (2017). *Historien à l'âge numérique*. Villeurbanne : Presses de l'Enssib, 207 p. DOI : 10.4000/books.pressenssib.6303.

Sinclair, S. & Rockwell, G. (2016). **Hermeneutica: Computer-Assisted Interpretation in the Humanities**. Cambridge : MIT Press.

Stab, C. & Gurevych, I. (2017). "Parsing argumentation structures in persuasive essays." **Computational Linguistics**, 43(3), p. 619-659.

Stack Overflow (2023). **Developer Survey 2023**. Disponible à : <https://survey.stackoverflow.co/2023/>.

Stephen E. Toulmin, *The uses of Argument*, 1958, ici, Cambridge Uni. Press, 2008.

Su, Y., Lin, Y. & Lai, C. (2023). "Collaborating with ChatGPT in argumentative writing classrooms." *Assessing Writing*, 57, 100752. <https://doi.org/10.1016/j.asw.2023.100752>

Underwood, T. (2019). **Distant Horizons: Digital Evidence and Literary Change**. Chicago : University of Chicago Press.

van Eemeren, F. H. & Grootendorst, R. (2004). **A Systematic Theory of Argumentation: The Pragma-Dialectical Approach**. Cambridge : Cambridge University Press.

Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A. N., Kaiser, Ł. & Polosukhin, I. (2017). "Attention is all you need." **Advances in Neural Information Processing Systems**, 30, p. 5998-6008.

Wang, L., Yang, N., Huang, X. et al. (2024). "Multilingual E5 text embeddings: A technical report." **arXiv**, 2402.05672.

Wieringa, R. J. (2014). **Design Science Methodology for Information Systems and Software Engineering**. Berlin : Springer.

Augmenter l'historien

Exemples de sorties du pipeline — Annexe

Cette annexe présente trois exemples de sorties réelles du pipeline, telles qu'elles ont été produites lors du travail sur un manuscrit relatif à l'histoire de l'extradition et de ses représentations médiatiques au XIXe siècle. Chaque bloc correspond à un niveau d'analyse distinct du dispositif.

Bloc	Niveau d'analyse	Exemple
A	Génération assistée	Synthèse sur la base du corpus
B	Cartographie critique (régime batch / RAG)	§1 du manuscrit — score de densité et sources qualifiées
C	Analyse approfondie sur segment (synthèse croisée)	Affaire Lamirande — Toulmin / Perelman / RST
D	Signaux de repérage (régime batch / CPT)	§18 et §46 — codes et recommandations

Dans chaque cas, la sortie brute est présentée telle quelle, suivie d'un court commentaire indiquant ce qu'elle a produit comme effet sur le manuscrit — signal suivi, nuancé ou ignoré, et pourquoi.

Ces exemples sont représentatifs sans être triomphants. Ils ont été choisis parce qu'ils illustrent bien les trois niveaux du dispositif et parce qu'ils montrent à la fois ce que le pipeline fait bien et les limites qu'il faut assumer.

Bloc A — Génération assistée : question en langue naturelle sur corpus

Cet exemple illustre la fonction RAG dans son usage le plus direct : l'historien pose une question en langue naturelle, le pipeline interroge le corpus, sélectionne les passages pertinents et produit un texte rédigé dont chaque énoncé est ancré dans une source identifiée et localisée. La consigne explicite l'attente de précision, de datation et d'ancrage exclusif dans le corpus — sans recours à des connaissances externes.

Consigne soumise au pipeline

« Rédige un texte décrivant l'évolution de l'infraction politique dans le cadre de l'extradition au XIXe et au XXe siècle, donne des exemples précis, date les évolutions, donne la référence des segments du corpus mobilisable et termine par une formule synthétisant l'évolution sans faire appel à des connaissances externes. »

Sources consultées par le pipeline (15 passages)

Le pipeline a interrogé l'index vectoriel et sélectionné 14 passages pertinents répartis sur cinq sources du corpus. Les sources mobilisables sont les suivantes :

Source	Passages sélectionnés	Pages représentatives
Recjurid132_3F — Revue juridique, recueil de jurisprudence	5	p. 2, 5, 6, 10
Traité de l'extradition	5	p. 52, 120, 124, 125, 127
Saint-Aubin — L'extradition et le droit extraditionnel	3	p. 29, 45, 421, 429, 433

Passage rédigé par le pipeline (extrait)

Le pipeline produit un texte rédigé en langue naturelle. Chaque énoncé factuel est suivi d'un renvoi au fichier source et à la page correspondante, permettant une vérification directe. Seul le premier paragraphe est reproduit ici .

L'évolution de l'infraction politique dans le cadre de l'extradition au XIXe et au XXe siècle illustre une transformation profonde des rapports entre souveraineté étatique, droit pénal et politique internationale. Initialement, sous l'Ancien Régime, l'extradition visait principalement les crimes contre la souveraineté, notamment le crime de lèse-majesté, considéré comme une atteinte à l'honneur de l'État. Ainsi, les actes qualifiés d'infractions politiques étaient ceux qui portaient atteinte à l'autorité du souverain, et leur répression relevait d'une logique d'honneur plus que d'une logique pénale classique. Cette conception se manifeste par des traités anciens, tels que celui conclu en 1174 entre Henri II d'Angleterre et le roi d'Écosse pour l'extradition réciproque des traîtres, ou encore la demande d'extradition formulée en 1413 par Charles VI au roi d'Angleterre pour des fauteurs de troubles parisiens [L'extradition et le droit extraditionnel_Saint_Aubin, p. 421-429].

Toutefois, cette approche évolue progressivement à partir des Lumières, qui introduisent une nouvelle conception de l'extradition tournée vers un but pénal et non plus uniquement politique. Ce changement s'accompagne d'une distinction juridique entre délits politiques et délits de droit commun, la qualification d'« infraction politique » devenant une expression juridique désignant un combat mené au nom d'un idéal politique, méritant une certaine mansuétude en considération des valeurs issues de 1789. Cette distinction se précise au XIXe siècle, notamment avec la reconnaissance par certains États, comme la France et la Belgique dès 1841, de l'exclusion des délits politiques du champ de l'extradition, tandis que d'autres pays, tels que le Danemark, la Suède, la Prusse, la Russie ou l'Autriche, continuent d'extrader pour crime de lèse-majesté [recjurid132_3F.pdf, p. 5]. [...]

Métadonnées de la requête

Modèle	gpt-4.1-mini (mode API)
Température	0.1
Passages candidats évalués	14
Corpus interrogé	Traités juridiques anciens + articles académiques (revue de droit <1914)
Contrainte de la consigne	Sans recours à des connaissances externes au corpus

Ce que l'historien en a fait

Le passage rédigé n'a pas été intégré directement au manuscrit — ce n'est pas sa fonction. Il a servi de matériau de travail : les références identifiées par le pipeline (notamment le Traité de l'extradition) ont été vérifiées dans les sources primaires et intégrées dans la section historiographique. La contrainte « sans connaissances externes » a été délibérément testée ici pour évaluer la cohérence du corpus : le pipeline a produit un texte daté et argumenté, signal signifiant que le corpus couvrait suffisamment bien la question pour ne pas nécessiter d'extension au regard de la fonction de cadrage large du passage.

Ce bloc illustre une propriété centrale du dispositif : la traçabilité des énoncés. Chaque affirmation produite par le pipeline renvoie à un segment localisé dans le corpus, ce qui permet à l'historien de vérifier, de contester ou d'écarter chaque élément indépendamment. Le texte produit n'est pas une synthèse autonome mais une proposition ancrée, soumise au jugement expert.

Bloc B — Cartographie critique (régime batch)

Paragraphe soumis (§1 du manuscrit)

« L'extradition est une procédure technique. Fréquente, réglée par des milliers de traités bilatéraux, elle s'exécute le plus souvent dans l'indifférence générale. Mais il suffit qu'une affaire retentissante la remette au premier plan — la longue cavale de Julian Assange, réclamé par Washington au Royaume-Uni, la lutte de Carles Puigdemont contre son extradition vers l'Espagne, la réouverture d'un couloir d'extradition entre la France et Dubaï — pour que resurgissent les questions anciennes sur les obligations qui lient des États souverains, la souveraineté sur les corps qui franchissent les frontières, et la propriété des fugitifs. »

Sortie du pipeline (régime batch)

Score de densité documentaire	0.80 (haut)
Profil dominant	Confirmation + nuance
Passages analysés	3 (sur 20 candidats)

Sources mobilisables identifiées par le pipeline

Relation	Source	Usage suggéré par le pipeline
citation	recjurid132_3F.pdf, p. 6	Définition juridique précise de l'extradition — peut renforcer l'ouverture du paragraphe en clarifiant sa nature juridique
citation	Saint-Aubin, p. 55	Illustre le paradoxe souveraineté / interdépendance (« assurance mutuelle contre le crime »)
note	Saint-Aubin, p. 51	Tensions entre souveraineté, asile et extradition — enrichit la réflexion sur les enjeux moraux et politiques

Manques identifiés par le pipeline

- Absence d'analyse approfondie des traités bilatéraux historiques et de leur rôle dans la formation de la société internationale
- Pas d'exemples d'affaires historiques anciennes illustrant l'évolution de la procédure
- Discussion absente sur les limites actuelles de la souveraineté étatique dans un contexte globalisé

Ce que l'historien en a fait

Signal partiellement suivi. La citation de Saint-Aubin sur l'« assurance mutuelle contre le crime » a été intégrée dans la version révisée du paragraphe, en note de bas de page, pour ancrer le paradoxe souveraineté/interdépendance. Les manques identifiés sur les traités bilatéraux ont été jugés hors du périmètre de l'article et ignorés.

Bloc C — Analyse approfondie sur segment (synthèse croisée)

Segment soumis — description de l’affaire Lamirande par la presse

« De ce fait, le cas Lamirande a suscité une correspondance serrée avec les autorités françaises, avant de devenir un cas célèbre, abondamment documenté, son retentissement ayant amené à la publication de la correspondance des autorités canadiennes relative au sujet. La presse française rend compte de chacun de ces épisodes, lui consacrant 259 articles durant les quelques mois de 1866 que durent sa cavale, sa traque, puis son retour et son procès. Cette mise en récit de la poursuite et du travail policier [...] est plus mutation du récit que transformation du lexique, qui semble en porter peu la trace. »

Modèle : gpt-4.1-mini | Température : 0.1 | Longueur : 2 857 caractères | Question posée : quelles sont les faiblesses probatoires du passage ?

Tableau de convergence des trois cadres

Dimension	A — Toulmin/Walton	B — Perelman	C — RST
Solidité argumentative	Robustesse : 0.50	Profil : 0.50	Relations d’élaboration (confiance haute)
Construction des preuves	Charge probatoire : 0.50	Ancrage auditoire : 0.50	Élaboration bien construite
Cohérence d’ensemble	Cohérence warrant : 0.50	Cohérence valeurs : 0.50	Noyau central : P1
Risques rhétoriques	Sophisme : aucun	Risque : 0.50, aucun détecté	0 relation basse confiance

Synthèse croisée (extrait)

L’argumentation du segment repose principalement sur une accumulation narrative et une autorité référentielle (presse, juristes, littérature policière) pour asseoir sa crédibilité. L’auteur dissocie clairement sa voix analytique des discours rapportés, ce qui renforce la clarté polyphonique. Cependant, la cohérence logique explicite entre preuves et conclusions reste partielle, avec des relations d’élaboration parfois peu assurées, ce qui peut nuire à la force démonstrative.

Recommandations du pipeline

- Renforcer la liaison explicite entre les preuves (articles de presse, analyses juridiques) et les conclusions analytiques (cf. RST)
- Clarifier les warrants sous-jacents pour solidifier la cohérence logique (cf. Toulmin)

Ce que l’historien en a fait

Signal suivi. La recommandation sur la loi de passage implicite a conduit à l’ajout d’une phrase explicitant le lien entre les 259 articles recensés et la conclusion sur la mutation narrative. Le signal sur le risque du discours rapporté non distingué a été considéré comme déjà géré par le texte et ignoré. Le diagnostic global — solidité référentielle mais loi de passage faible — correspond à une tendance récurrente dans l’écriture de textes courts à destination académique, sous contrainte de signes, où les étapes du raisonnement sont comprimées, le destinataire étant censé lire ce qui n’est pas écrit par vertu de son habitus.

Bloc D — Signaux de repérage (régime batch / CPT)

Le régime batch analyse le manuscrit paragraphe par paragraphe et produit des signaux courts orientés vers le repérage. Voici deux exemples représentatifs, issus du même passage.

§18 — Signal composé

Signaux détectés	A : rhéto_sans_preuve F : coherence_axiologique
Robustesse / Profil	0.50 (modèle 09) 0.73 (modèle 10)
Warrant / Force	0.80 0.70
Risque sophisme	0.90 (09) 0.10 (10) — divergence inter-modèles
Schème Walton	autorité
Technique Perelman	argument_pragmatique
Scripts recommandés	Script A (Toulmin sur segment) Script B (Perelman)

Interprétation du signal A (rhéto_sans_preuve) : robustesse logique faible mais profil rhétorique fort — l’auteur argumente efficacement sans étayer. Candidat prioritaire pour une analyse Toulmin sur segment. Signal F (coherence_axiologique) : forte cohérence de valeurs, risque sophistique bas — zone rhétoriquement solide. Signal positif.

Note sur la divergence inter-modèles : le modèle 09 signale un risque sophistique à 0.90 quand le modèle 10 le juge à 0.10. Cette divergence, plutôt que d’être masquée, est documentée dans la sortie et signalée à l’utilisateur comme une zone d’incertitude à trancher par le jugement expert.

§46 — Signal composé avec alerte de cohérence discursive

Signaux détectés	A : rhéto_sans_preuve D : 09_muet_10_parle F : coherence_axiologique
Robustesse / Profil	0.50 (09) 0.75 (10) — divergence signalée
Schème Walton	autorité
Technique Perelman	argument_autorite
Scripts recommandés	Script A (Toulmin) Script B (Perelman) Script C (RST)

Signal D (09_muet_10_parle) : le modèle 09 n’a pas identifié d’argument (score neutre 0.50) mais le modèle 10 voit une rhétorique active. Interprétation suggérée par le pipeline : discours rapporté, conclusion narrative, ou liste bibliographique. À examiner pour confirmer si c’est voulu. Le script RST est recommandé plutôt que Toulmin : le problème est peut-être de cohérence discursive entre les phrases plutôt qu’argumentatif.

Ce que l’historien en a fait

Signal §18 suivi : le passage a été soumis au script A (Toulmin) sur le segment élargi, confirmant la faiblesse de la loi de passage. Révision effectuée. Signal §46 partiellement suivi : la divergence inter-modèles sur le signal D a incité à relire le paragraphe, qui s’est avéré contenir une citation longue non clairement introduite pouvant conduire le lecteur pressé à une fausse attribution. Reformulation du chapeau. Le script RST n’a pas été lancé — le problème était visible à la lecture une fois l’attention attirée dessus.

Ces trois blocs illustrent la chaîne complète du dispositif : du signal batch orienté vers le repérage (Bloc C), à la cartographie critique par confrontation au corpus (Bloc A), jusqu’à l’analyse approfondie sur segment (Bloc B). Dans chaque cas, le pipeline produit des signaux que l’historien est libre de suivre, de nuancer ou d’ignorer — ce que ces commentaires documentent explicitement.

ⁱ Avec tous mes remerciements à l’Inria pour m’avoir offert un cadre rendant ce projet possible, à mes camarades de l’équipe Semis, à Eric Guichard, même s’il pense toujours que perl c’est mieux, pour n’être jamais à court d’une objection amicale et aux animateurs de ce merveilleux lieu qu’est l’IXXI pour l’avoir

rendu pensable, à tous les amoureux et les amoureuses de la science dont l'exemple stimule et nourrit autant qu'il oblige.

ⁱⁱ Les scripts, la documentation, les exemples de sorties et le corpus de démonstration sont disponibles en libre accès sur GitHub : <https://github.com/Datashs/Git/tree/main/AugmentingHistorian>.